Universidad Tecnológica del Perú

# Modelo hibrido para detectar el alcoholismo a partir de señales EEG utilizando Deep Learning y Machine Learning

**ARTÍCULO CIENTÍFICO**

PRESENTADO POR:
Bach. Gherson Steven Torres Otrera

para optar por el título de ingeniero de software

ASESOR:
Mg. Ing. Wilfredo Mamani Ticona

2026

# A G E N D A

1. Realidad Problemática
2. Objetivos de la investigación
3. Marco Teórico
4. Desarrollo de la Metodología
5. Desarrollo de la Solución
6. Resultados
7. Demostración del Modelo
8. Conlusiones

# PART.01

## REALIDAD PROBLEMÁTICA

# 1 REALIDAD PROBLEMÁTICA

## En el mundo

El alcoholismo es una crisis mundial que causa, en promedio, 3 millones de muertes al año (5,3 % del total) y se asocia con más de 200 enfermedades, como la cirrosis y los problemas cardiovasculares.

Fuente: WHO; 2024

## En Latinoamérica

En Latinoamérica, el alcoholismo es un problema de salud pública que causa cerca de 85 000 muertes al año y su consumo supera el promedio mundial.

Fuente: PAHO; 2024

## En Perú

En el Perú, el alcoholismo es un grave problema de salud pública; afecta entre 1,5 y 2 millones de adultos y está relacionado con miles de muertes cada año.

Fuente: MINSA; 2025

# 1 REALIDAD PROBLEMÁTICA

## SITUACIÓN ACTUAL

Paciente ingresa al hospital

Consulta médica

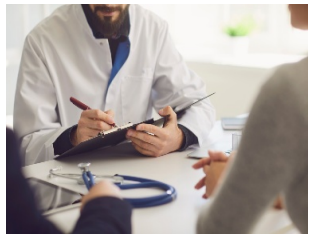

Pruebas para determinar el alcoholismo

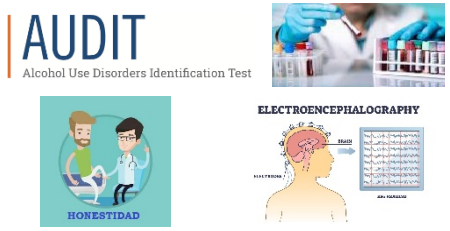


**Diagnóstico de Alcoholismo**

Evaluación de Resultados

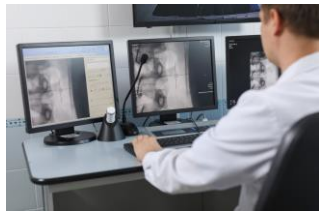

Doctor entrega diagnostico y tratamiento

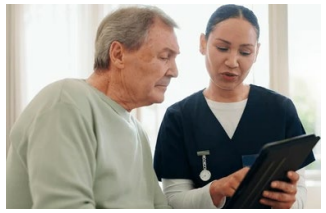

## Problemas

- Costos elevados
- Detección tardía
- Honestidad del paciente; negación.
- Procesos lentos.
- Acceso limitado a especialistas

# 1 REALIDAD PROBLEMÁTICA

## SOLUCIÓN PROPUESTA

Paciente ingresa al hospital.

Consulta médica.

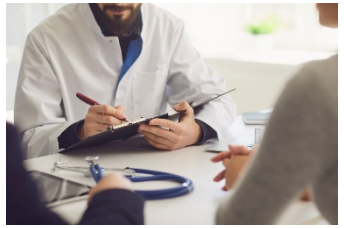

Prueba de EEG para el determinar el alcoholismo.

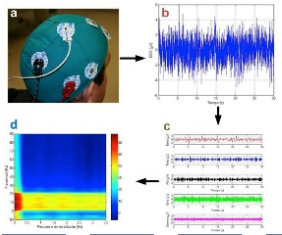

**Deep Learning y Machine Learning**

Recolección de datos y uso de DL y ML.

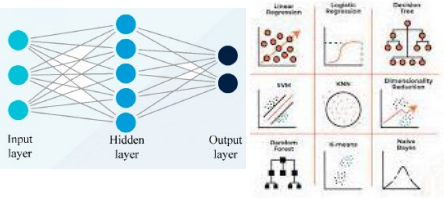


Detección de alcoholismo a través EEG por modelo hibrido.

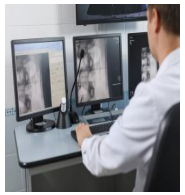

Doctor entrega diagnostico y tratamiento.

## Beneficios

- Detección basada mediante señales del cerebro.
- Reducción de costes y diagnóstico a tiempo
- Gestión de grandes volúmenes de datos clínicos.
- Apoyo a la toma de decisiones médicas.
- Mayor acceso a diagnósticos de calidad.

# PART.02

## OBJETIVOS DE LA INVESTIGACIÓN

# 2 OBJETIVOS DE LA INVESTIGACIÓN

## Objetivo general

Implementar un modelo hibrido para detectar el alcoholismo a partir de señales EEG utilizando Deep Learning y Machine Learning.

# 2 OBJETIVOS DE LA INVESTIGACIÓN

## Objetivos específicos

1. Recopilar el conjunto de datos de EEG de alcoholismo.“Wavelet-Transformed EEG Data for Alcohol Detection”de Kaggle.

2. Preprocesar el conjunto de datos de escalogramas EEG; aplicando redimensionamiento; normalización; etiquetado y creación de datos de pruebas.

3. Implementar modelos híbridos utilizando arquitecturas de DL (ViT; PiT; CNN; MobileNetV2; BotNet y MLPMixer) como extractores de características de las imágenes EEG; y entrenar clasificadores de ML (SVM; RF y k-NN) con las características extraídas; optimizando hiperparámetros.

4. Evaluar el desempeño de los modelos híbridos mediante métricas estándar (exactitud; precisión; sensibilidad y F1-Score) para determinar el mejor modelo.

# PART.03

## MARCO TEÓRICO

## VARIABLE DEPENDIENTE

### Alcoholismo

El alcoholismo se ha consolidado como una amenaza considerable para la salud; desgastando no solo el cuerpo; sino también la mente y la vida de millones de personas. Se caracteriza por un consumo problemático que expone a la persona al riesgo de dependencia y se relaciona con numerosas enfermedades crónicas y diversos trastornos psiquiátricos. (WHO; 2024)

# VARIABLE INDEPENDIENTE

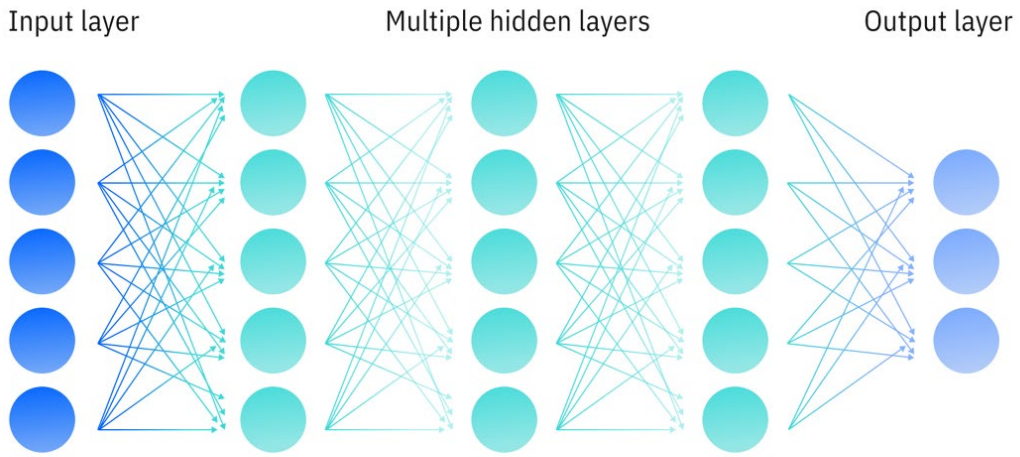


## Deep Learning

Deep Learning es una subrama del Machine Learning que utiliza redes neuronales profundas; formadas por muchas capas; para aprender automáticamente representaciones cada vez más complejas de los datos (por ejemplo; imágenes EEG) y lograr un alto rendimiento en tareas como clasificación o detección de patrones. (IBM; 2025)

# VARIABLE INDEPENDIENTE

## Machine Learning

El Machine Learning es un área de la inteligencia artificial que se centra en algoritmos capaces de aprender de los datos para reconocer patrones y hacer predicciones sin que se les programe explícitamente cada regla. (IBM; 2025)

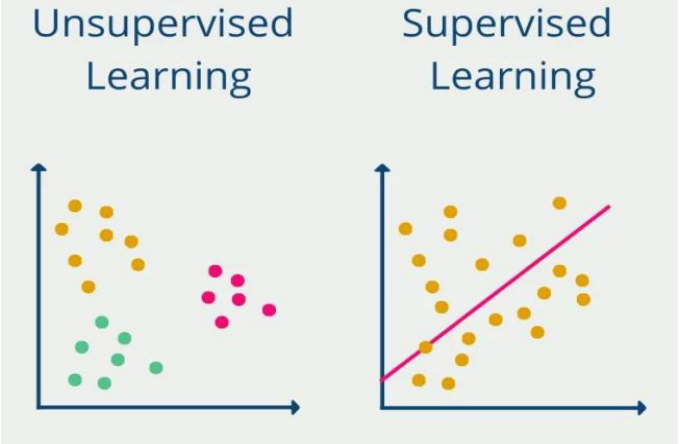


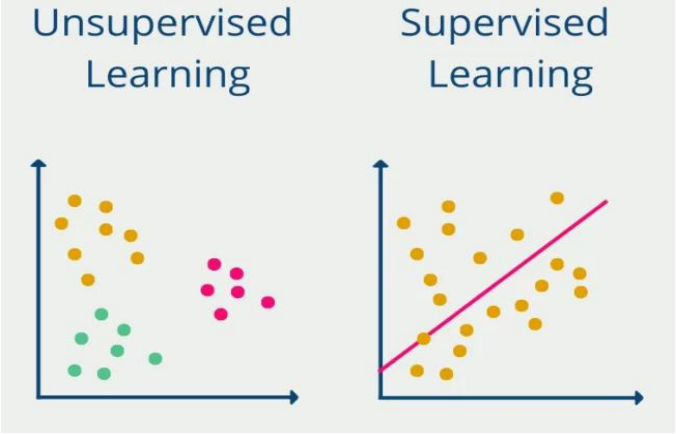

# PART.04

## DESARROLLO DE LA METODOLOGÍA

# 4 DESARROLLO DE LA METODOLOGÍA

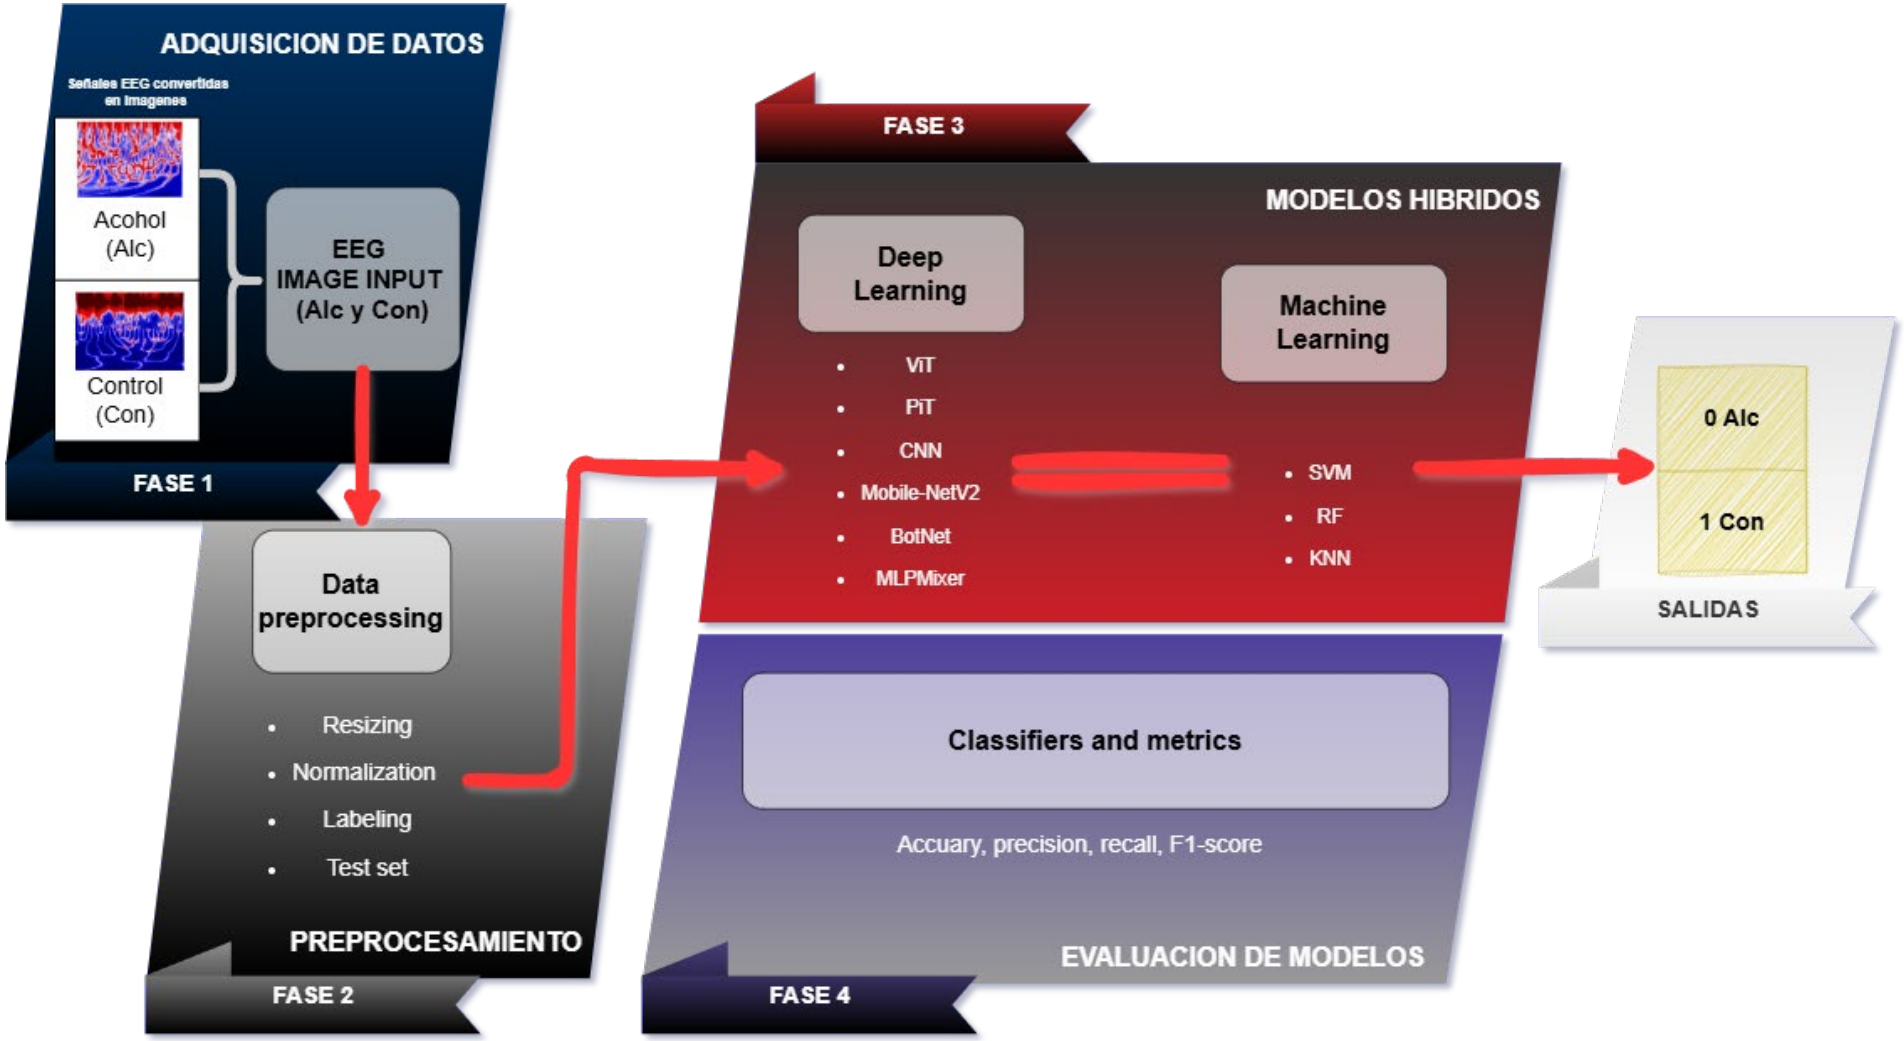

# PART.05

## DESARROLLO DE LA SOLUCIÓN

# 5 DESARROLLO DE LA SOLUCIÓN

## FASE 1: ADQUISICIÓN DE DATASET

kaggle

### Acerca del conjunto de datos:

**DATOS DE ORIGEN:**

Señales de EEG del conjunto de datos de EEG de UCI.

**PREPROCESAMIENTO:**

Aplicación de CWT para extraer características tiempo-frecuencia.

Generación de escalogramas a partir de la señal EEG.

Ajuste de dimensiones a 200x172 px para el modelo.

**ESTRUCTURA DEL CONJUNTO DE DATOS:**

Dos clases: alcohólica y de control.
Total de imágenes: 924 (468 alcohólicas; 456 de control).

**EEG** (2 directories)

**About this directory**

```
Wavelet_EEG_Dataset/
├── README.md
├── Alcoholic/
│   ├── subject1_channel1.jpg
│   ├── subject1_channel2.jpg
│   └── ...
├── Control/
│   ├── subject2_channel1.jpg
│   ├── subject2_channel2.jpg
│   └── ...
```

Alcoholic

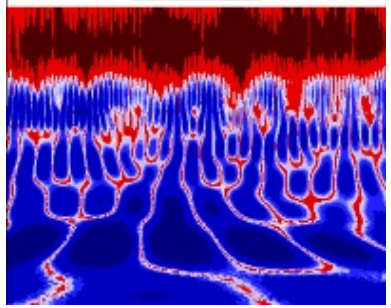

Control

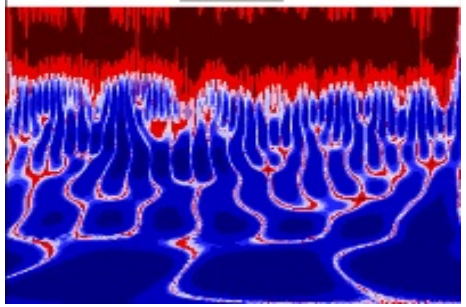

Fuente: **Kaggle (Wavelet-Transformed EEG Data for Alcohol Detection)**

https: //www.kaggle.com/datasets/muhammedjunayed/wavelet-transformed-eeg-data-for-alcohol-detection

## FASE 2: PREPROCESAMIENTO

### Actividad 01: Redimensionamiento

Ajuste de 200x172 px a 224x224 px.

Crucial para modelos Deep Learning (ViT; PiT; MobileNetV2 y otros).

Garantiza medidas uniformes para la entrada del modelo.

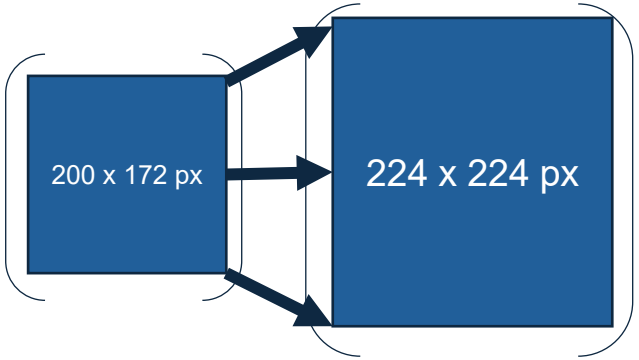


En el código

```
from sklearn.model_selection import train_test_split
from tensorflow.keras.utils import load_img, img_to_array

# Definir tamaño de imagen (224x224estándar para muchos modelos pre-entrenados)
IMG_SIZE = (224, 224)
X = []
y = []
```

## FASE 2: PREPROCESAMIENTO

### Actividad 02: Normalización

Conversión de valores de píxeles (0-255) a un rango continuo [0;1].

Se aplica $I_{norm}$: $\frac{I}{255}$

Garantiza estabilidad numérica durante el entrenamiento.

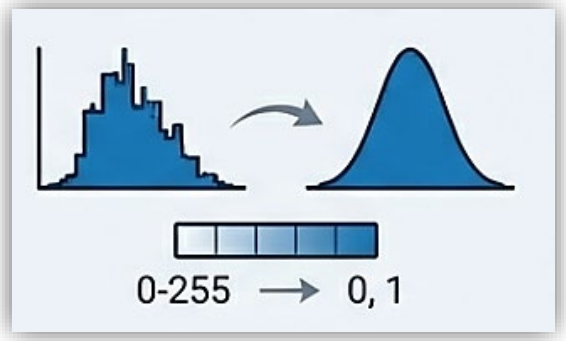


En el código

```
# Convertir a arrays de numpy
X = np.array(X)
y = np.array(y)

# Normalizar valores de píxeles a [0, 1]
X = X / 255.0
```

# 5 DESARROLLO DE LA SOLUCIÓN

## FASE 2: PREPROCESAMIENTO

### Actividad 03: Etiquetado y set de prueba

**Asignación binaria:**

0 : Control (Con).

1 : Alcohólico (Alc).

En el código

```
# Cargar datos de Alcohol (1) y Control (0)
# Usando variables 'alc_dir' y 'con_dir' de celdas anteriores
load_images_from_dir(alc_dir, 1, "Alcohol")
load_images_from_dir(con_dir, 0, "Control")
```

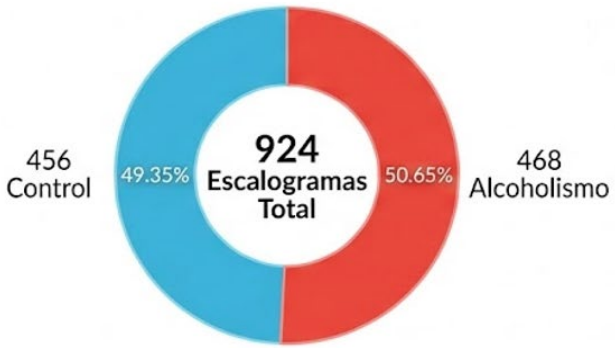


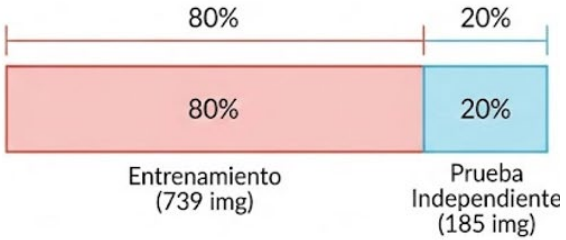


En el código

```
# Dividir en conjuntos de entrenamiento y prueba (80% train, 20% test)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)
```

# 5 DESARROLLO DE LA SOLUCIÓN

## FASE 3: Modelo Híbridos

**EXTRACCION DE CARACTERISTICAS DEEP LEARNING:**
Se evaluaron 6 arquitecturas de DL para extraer características.

### ViT (Vision Transformer)

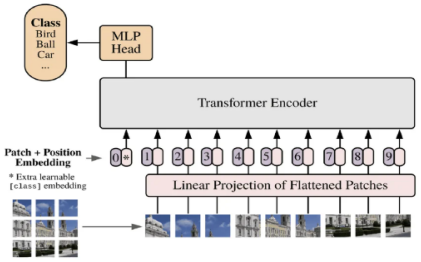


### PiT (Pooling ViT)

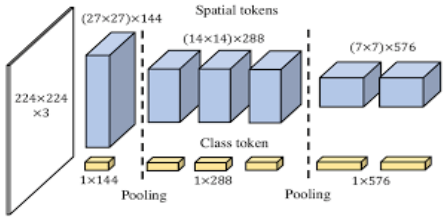


### CNN

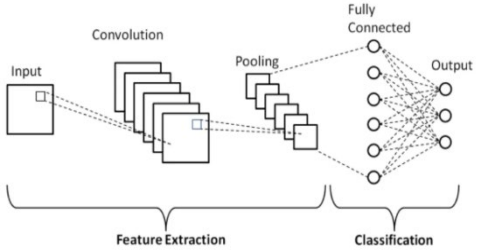


### MobileNetV2

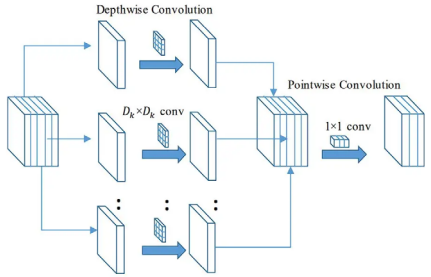


### BotNet

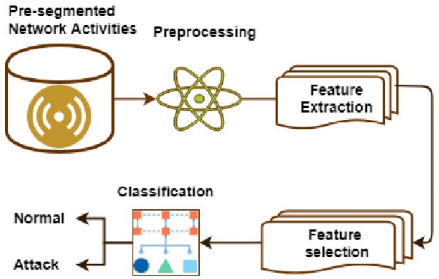


### MLPMixer

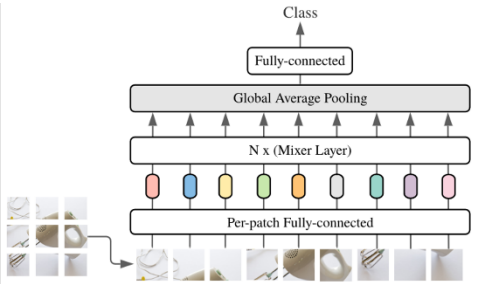

# 5 DESARROLLO DE LA SOLUCIÓN

## FASE 3: Modelo Híbridos

CLASIFICACIÓN ROBUSTA MACHINE LEARNING

### SVM (Support Vector Machine)

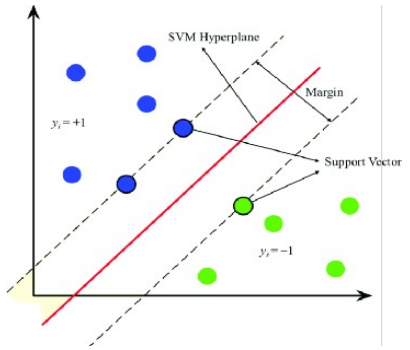


Busca el límite óptimo (hiperplano) que maximiza la distancia entre ‘Control' y 'Alcohólico’.

### RF (Random Forest)

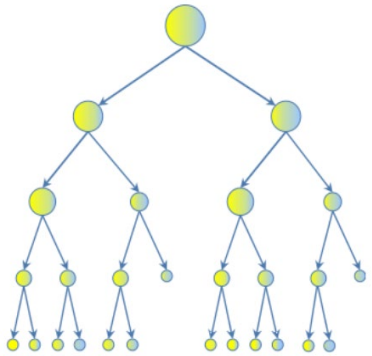

Toma decisiones basadas en el voto mayoritario de múltiples árboles de decisión.

### k-NN (K-Nearest Neighbors)

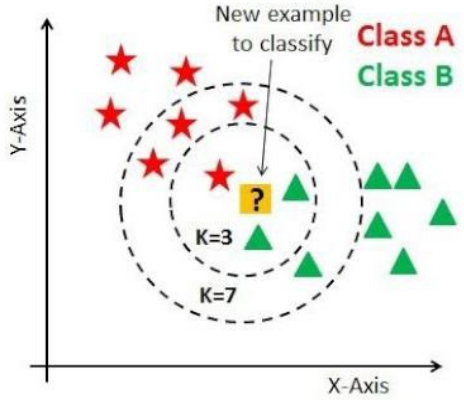


Clasifica según la similitud con los vecinos más cercanos en el espacio de datos.

# 5 DESARROLLO DE LA SOLUCIÓN

## FASE 4: EVALUACIÓN DE MODELOS

### Carga de modelos de Deep Learning

```
# --- Aplicar Inyección ---
defaults = {'input_shape': (224, 224, 3), 'n_classes': 2}
for cls in [ViTClassfier, PiTClassifier, CNNClassifier, BotNetClassifier, MLPMixer]:
    inject_robust_from_config(cls, defaults)
```

```
if 'loaded_models' in locals():
    for name, model in loaded_models.items():
        try:
            # 4. Identificar modelo funcional de Keras
            if hasattr(model, '_model'):
                functional_model = model._model
            else:
                functional_model = model
```

```
=== Resultados Finales de Extracción de Características ===
Modelo: ViT            | Train Shape: (739, 1024)     | Test Shape: (185, 1024)
Modelo: PiT            | Train Shape: (739, 128)      | Test Shape: (185, 128)
Modelo: CNN            | Train Shape: (739, 512)      | Test Shape: (185, 512)
Modelo: BotNet         | Train Shape: (739, 2048)     | Test Shape: (185, 2048)
Modelo: MLPMixer       | Train Shape: (739, 256)      | Test Shape: (185, 256)
Modelo: MobileNetV2    | Train Shape: (739, 128)      | Test Shape: (185, 128)
```

### Carga de modelos de Machine Learning

**Tuneo de Hiperparámetros**

- SVM

```
param_grid_svm = {
    'svm__C': [0.1, 1, 10],
    'svm__kernel': ['linear', 'rbf'],
    'svm__gamma': ['scale', 0.01]
}
```

- RF

```
param_grid_rf = {
    'rf__n_estimators': [100, 200, 300],
    'rf__max_depth': [None, 20],
    'rf__min_samples_leaf': [1, 2]
}
```

- K-NN

```
param_grid_knn = {
    'knn__n_neighbors': [5, 15, 25],
    'knn__weights': ['distance'],
    'knn__metric': ['cosine', 'euclidean']
}
```

**Mejores parámetros**

$SVM: \{'C': 0.1; 'Kernel': linear; 'gamma': scale\}$

# 5 DESARROLLO DE LA SOLUCIÓN

## FASE 4: EVALUACIÓN DE MODELOS

**Accuracy:**

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}$$

**Precision:**

$$\text{Precision} = \frac{TP}{TP + FP}$$

**Recall:**

$$\text{Recall} = \frac{TP}{TP + FN}$$

**F1-Score:**

$$\text{F1-score} = \frac{2(\text{Recall} * \text{Precision})}{\text{Recall} + \text{Precision}}$$

**Curva ROC:**

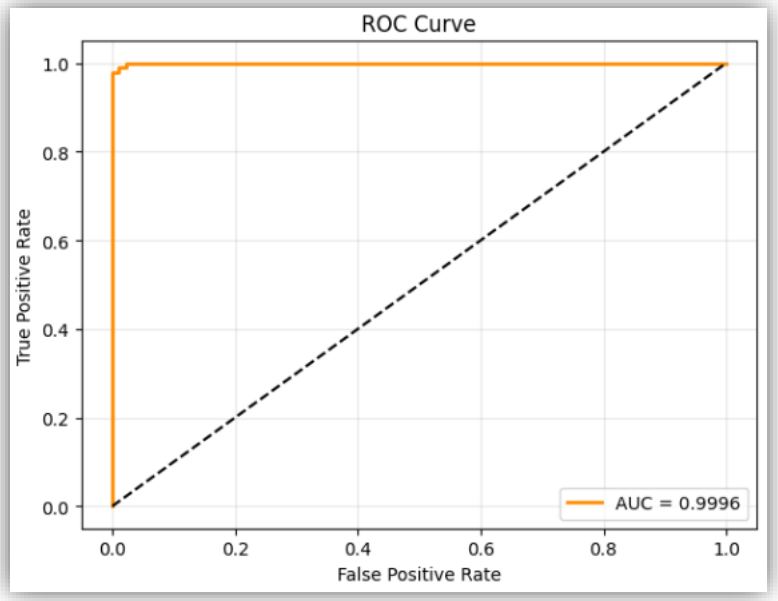


**Matriz de Confusion:**

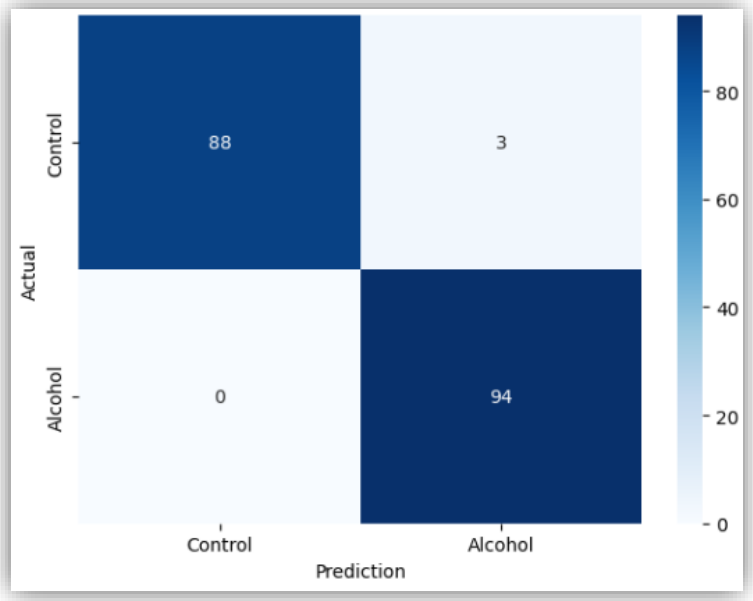

# PART.06

## RESULTADOS

# 6 RESULTADOS

| | | Accuracy | Precision | Recall | F1-Score | Hiperparámetros |
|---|---|---|---|---|---|---|
| **ViT** | **SVM** | **0.9838** | **0.9691** | **1.000** | **0.9843** | **C: 0.1; Kernel: linear; Gamma: scale** |
| | RF | 0.9297 | 0.9263 | 0.9362 | 0.9312 | N_Est: 300; Depth: None; MinSamples: 2 |
| | KNN | 0.8757 | 0.8515 | 0.9149 | 0.8821 | K: 15; Weights: distance; Metric: cosine |
| **PiT** | SVM | 0.6054 | 0.6105 | 0.6170 | 0.6138 | C: 0.1; Kernel: linear; Gamma: scale |
| | RF | 0.6108 | 0.6196 | 0.6064 | 0.6129 | N_Est: 100; Depth: 20; MinSamples: 2 |
| | KNN | 0.6000 | 0.5909 | 0.6915 | 0.6370 | K: 25; Weights: distance; Metric: cosine |
| **CNN** | SVM | 0.9459 | 0.9286 | 0.9681 | 0.9479 | C: 1; Kernel: rbf; Gamma:scale |
| | RF | 0.9405 | 0.9109 | 0.9787 | 0.9436 | N_Est: 300; Depth: None; MinSamples: 1 |
| | KNN | 0.9459 | 0.9468 | 0.9468 | 0.9468 | K: 15; Weights: distance; Metric: cosine |
| **MobileNetV2** | SVM | 0.6270 | 0.6404 | 0.6064 | 0.6230 | C: 1; Kernel: rbf; Gamma: 0.01 |
| | RF | 0.5622 | 0.5684 | 0.5745 | 0.5714 | N_Est: 300; Depth: None; MinSamples: 1 |
| | KNN | 0.5568 | 0.5625 | 0.5745 | 0.5684 | K: 15; Weights: distance; Metric: cosine |
| **BotNet** | SVM | 0.5946 | 0.6234 | 0.5106 | 0.5614 | C: 0.1; Kernel: linear; Gamma: scale |
| | RF | 0.6270 | 0.6344 | 0.6277 | 0.6310 | N_Est: 200; Depth: 20; MinSamples: 2 |
| | KNN | 0.6432 | 0.6628 | 0.6064 | 0.6333 | K: 15; Weights: distance; Metric: euclidean |
| **MLPMixer** | SVM | 0.6486 | 0.6593 | 0.6383 | 0.6486 | C: 1; Kernel: rbf; Gamma: scale |
| | RF | 0.6757 | 0.6771 | 0.6915 | 0.6486 | N_Est: 300; Depth: None; MinSamples: 2 |
| | KNN | 0.6541 | 0.6630 | 0.6489 | 0.6559 | K: 15; Weights: distance; Metric: cosine |

Evaluación del desempeño de modelos híbridos, empleando Deep Learning para la extracción de características y Machine Learning para la clasificación, con ajuste de hiperparámetros.

## RESULTADOS DEL MEJOR MODELO HÍBRIDO

**ViT + SVM**

| | |
|---|---|
| **98,38%** Exactitud / Accuracy | **100%** Sensibilidad / Recall |
| **96,91%** Precision | **98,43%** F1-Score |

**Dato clave: 100% Sensibilidad** significa que el modelo **no omitió** NINGUN caso positivo de alcoholismo.

# 6 RESULTADOS

## Matriz de confusión ViT + SVM

Matriz de confusión con 88 VN (controles correctos), 3 FP (alertas mínimas), 0 FN (sin omisiones de alcohólicos) y 94 VP (detección precisa), logrando precisión casi perfecta en EEG.

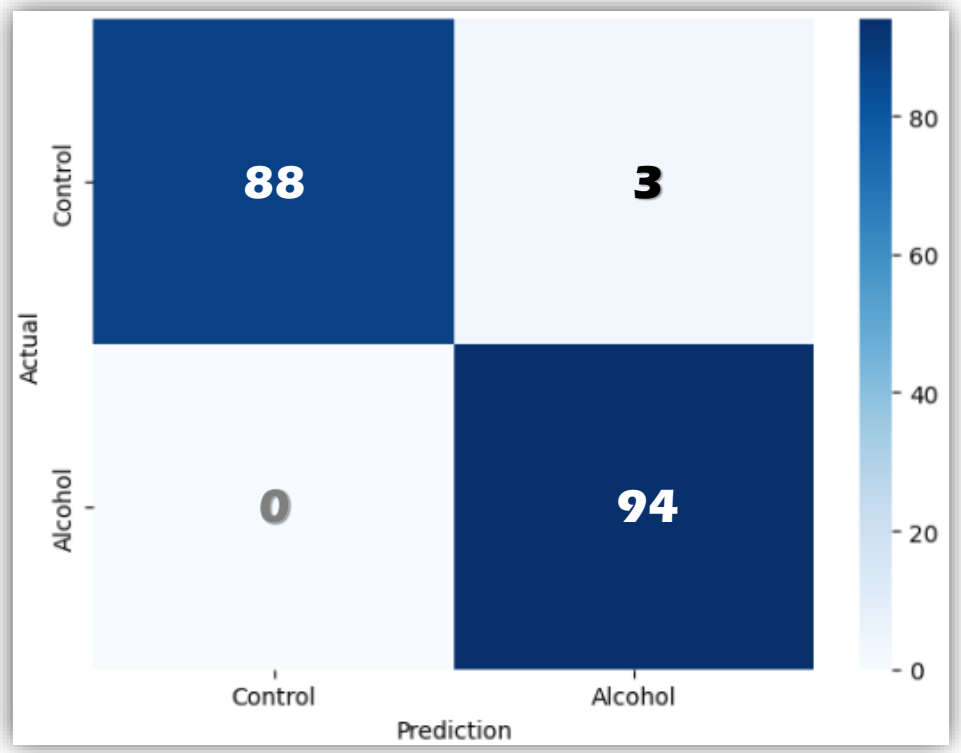


## Curva ROC de ViT + SVM

La curva ROC muestra AUC=0.9996 con ascenso vertical, identifica prácticamente todos los casos reales de alcoholismo, al tiempo que mantiene un mínimo de falsos positivos

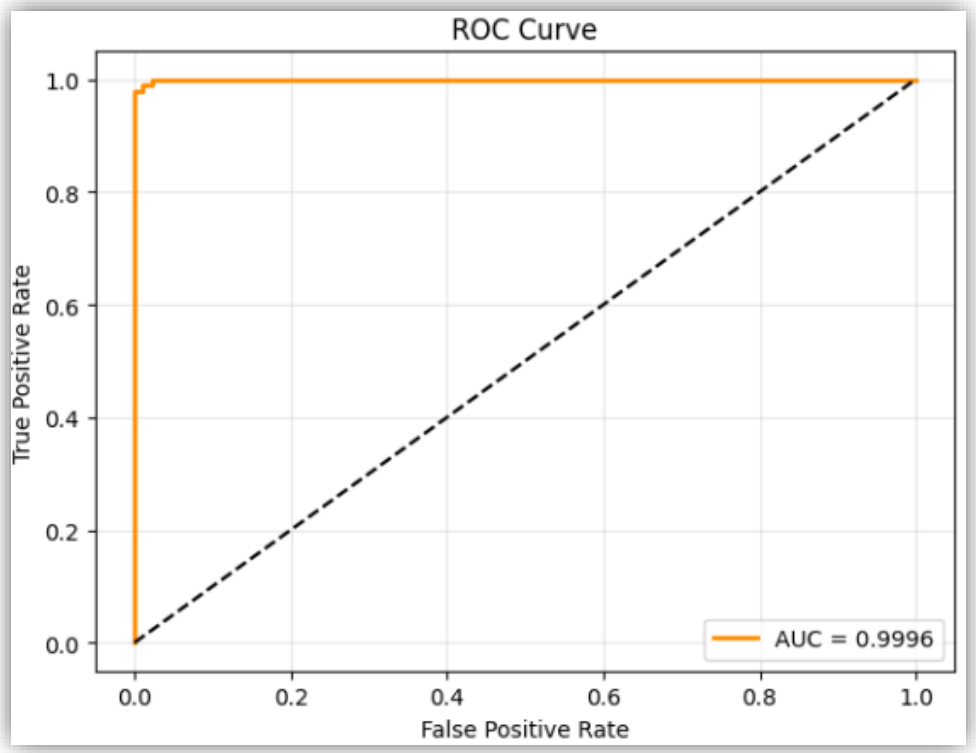

# PART.07

## DEMOSTRACIÓN DEL MODELO

# 7 DEMOSTRACIÓN DEL MODELO

**Entorno de desarrollo:**

Google colab

**Lenguaje de programación:**

python™

**Librerías y Frameworks**

Keras

TensorFlow

NumPy

scikit learn

matplotlib

seaborn

pandas

# PART.08

## CONCLUSIONES

# 8 CONCLUSIONES

El estudio demostró la eficacia de implementar de modelos híbridos para la detección de alcoholismo a partir de señales EEG, combinando técnicas de Deep Learning y Machine Learning.

1. Se recopiló un data set EEG de alcoholismo en UCI con un total de 924 imágenes distribuidas en 468 imágenes de personas con alcoholismo y 456 de control.

2. Se aplicó redimensionamiento; normalización; etiquetado y creación de datos de pruebas para garantizar un adecuado preprocesamiento del conjunto de datos de escalogramas EEG.

3. Se implementarón modelos híbridos utilizando arquitecturas de Deep Learning (ViT; PiT; CNN; MobileNetV2; BotNet y MLPMixer) como extractores de características de las imágenes EEG; y entrenar clasificadores de Machine Learning (SVM; RF y k-NN) con las características extraídas; optimizando hiperparámetros.

4. Se concluye que el modelo hibrido ViT + SVM propuesto es el más efectivo, obteniendo un Accuaracy del 98,38%, un Precision del 96,91%, un Recall del 100%, un F1-Score del 98,43% y un de 0,99 de AUC para la curva ROC, demostrando confiabilidad para un diagnostico temprano y confiable del alcoholismo.

# Torres Otrera, Gherson Steven

Universidad Tecnológica del Perú, Lima, Perú.

https://orcid.org/0009-0007-8444-597X


## Hybrid Model for Detecting Alcoholism from EEG Signals using Deep Learning and Machine Learning

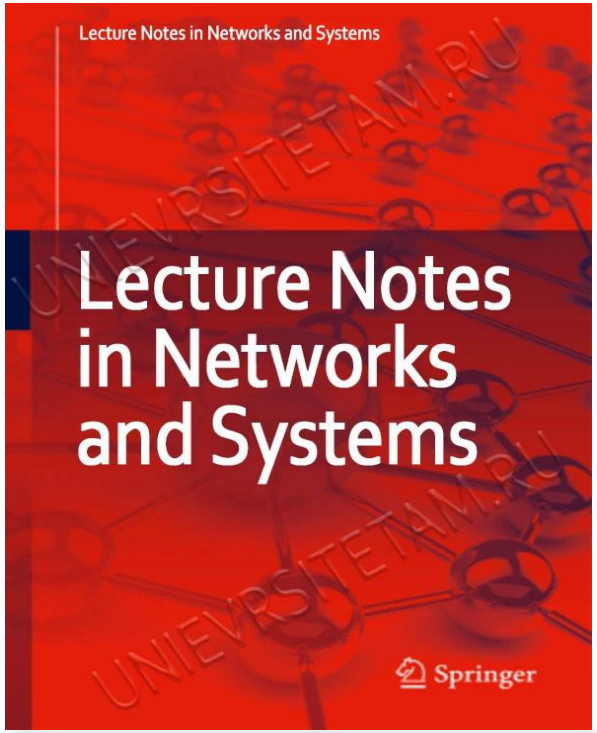


**LETTER OF ACCEPTANCE**

15th Computer Science On-line Conference 2026

Dear Wilfredo Ticona,

Organizing & Program Committee is pleased to announce that your paper:

**Hybrid Model for Detecting Alcoholism from EEG Signals using Deep Learning and Machine Learning (Paper ID: 113828)**

Author(s): Gherson Steven Torres Otrera,

**was Accepted**

for the 15th Computer Science On-line Conference 2026.

For finishing your registration follow instruction, which has been already sent by e-mail to all authors of accepted papers (or follow instruction on https://csoc.openpublish.eu)

CSOC2026 is held on-line from 4/23/2026 to 4/26/2026.

Conference organization (sponsored by): OpenPublish.eu

Organization Committee Chair:
Radek Silhavy, Ph.D.

Radek Silhavy, Ph.D.
Organizing Committee Chair

# GRACIAS